

UJIAN TENGAH SEMESTER
ANALITIK DAN VISUALISASI DATA
TINGKAT KEHADIRAN SISWA DAN DAMPAK NYA
TERHADAP PRESTASI AKADEMIK



Disusun Oleh:
ALIF ANUGRAH RAMADHAN
2509116019

PROGRAM STUDI SISTEM INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS MULAWARMAN
2026

KATA PENGANTAR

Puji syukur penulis panjatkan kehadiran Tuhan Yang Maha Esa, karena atas rahmat dan karunia-Nya, penulis dapat menyelesaikan tugas analisis data yang berjudul **”Tingkat Kehadiran Siswa dan Dampaknya terhadap Prestasi Akademik”** ini tepat pada waktunya.

Tugas ini disusun untuk memenuhi salah satu kewajiban akademik dalam memahami proses pengolahan data secara menyeluruh, mulai dari tahap *Business Understanding* hingga *Data Preparation* dan visualisasi. Melalui pemanfaatan dataset *Vocational Student Behavioral*, penulis mencoba membedah bagaimana pola kehadiran memberikan pengaruh nyata terhadap capaian nilai akhir siswa di lingkungan pendidikan vokasi.

Penulis menyadari bahwa selesainya tugas ini tidak terlepas dari dukungan berbagai pihak. Oleh karena itu, penulis menyampaikan terima kasih kepada:

1. Bapak Dosen dan Praktisi Pengampu mata kuliah yang telah memberikan bimbingan dan ilmu dalam penyusunan tugas ini.
2. Rekan-rekan mahasiswa angkatan 2025 program studi Sistem Informasi Universitas Mulawarman yang telah bertukar pikiran selama proses pengerjaan.
3. Seluruh pihak yang telah membantu, baik secara langsung maupun tidak langsung.

Penulis menyadari bahwa laporan ini masih jauh dari kata sempurna. Oleh karena itu, kritik dan saran yang membangun sangat penulis harapkan demi perbaikan di masa mendatang. Akhir kata, semoga hasil analisis ini dapat memberikan manfaat bagi pembaca dan perkembangan ilmu pengetahuan di bidang analisis data.

Samarinda, April 2026

DAFTAR ISI

KATA PENGANTAR.....	ii
DAFTAR ISI.....	iii
DAFTAR GAMBAR.....	v
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Tujuan Analisis	1
BAB II PEMBAHASAN.....	2
2.1 Business Understanding	2
2.1.1 Business Objective.....	2
2.1.2 Assess Situation	2
2.1.3 Analytic Goals	2
2.1.4 Project Plan	3
2.2 Data Understanding	3
2.2.1 Memuat Dataset	3
2.2.2 Melihat Struktur Data	4
2.2.3 Statistik Deskriptif	5
2.2.4 Verifikasi Kualitas Data.....	5
2.2.5 Inconsistensi Values.....	5
2.2.6 Missing Values.....	5
2.2.7 Duplicated Values	6
2.2.8 Outliers Values.....	6
2.3 Eksplorasi Data (EDA)	6
2.3.1 Comparison	7
2.3.2 Composition.....	8
2.3.3 Distribution	9

2.3.4 Relationship	10
2.4 Data Preparation	12
2.4.1 Inconsistent Values	12
2.4.2 Missing Values.....	13
2.4.3 Duplicated Values.....	14
2.4.4 Outliers Values.....	14
2.4.5 Data Reduction.....	16
2.5 Visualisasi Data (Tableau).....	17
2.5.1 Pie Chart.....	17
2.5.2 Bar Chart.....	18
2.5.3 Scatter Plot.....	18
2.5.4 Histogram.....	19
2.6 Dashboard	20
2.7 Hasil Analisis.....	21
BAB III PENUTUP.....	23
3.1 Kesimpulan	23
3.2 Saran	23

DAFTAR GAMBAR

Gambar 2. 1 Comparison.....	8
Gambar 2. 2 Composition	9
Gambar 2. 3 Distribution.....	10
Gambar 2. 4 Relationship.....	11
Gambar 2. 5 Pie Chart	17
Gambar 2. 6 Bar Chart	18
Gambar 2. 7 Scatter Plot.....	19
Gambar 2. 8 Histogram	20
Gambar 2. 9 Dashboard.....	20

BAB I

PENDAHULUAN

1.1 Latar Belakang

Data memiliki peran yang sangat penting dalam mendukung proses pengambilan keputusan di berbagai bidang, termasuk dalam sektor pendidikan. Dengan memanfaatkan data yang tersedia, institusi pendidikan dapat melakukan analisis yang lebih mendalam untuk memahami faktor-faktor yang mempengaruhi keberhasilan akademik siswa.

Salah satu faktor yang sering dikaitkan dengan keberhasilan akademik adalah tingkat kehadiran siswa dalam kegiatan pembelajaran. Kehadiran mencerminkan tingkat keterlibatan siswa dalam proses belajar mengajar. Siswa yang memiliki tingkat kehadiran tinggi umumnya memiliki kesempatan lebih besar untuk memahami materi yang diberikan oleh pengajar.

Selain kehadiran, terdapat berbagai faktor lain yang dapat mempengaruhi performa akademik siswa, seperti aktivitas belajar daring, durasi belajar, frekuensi penggunaan sumber belajar, serta kebiasaan belajar yang dimiliki oleh setiap siswa.

Data tersebut kemudian dapat dianalisis menggunakan teknik Analitik Data untuk menemukan pola, hubungan antar variabel, serta insight yang dapat digunakan untuk meningkatkan kualitas pembelajaran.

Melalui pendekatan Exploratory Data Analysis (EDA) dan visualisasi data, analisis terhadap perilaku belajar siswa dapat memberikan gambaran yang lebih jelas mengenai hubungan antara aktivitas belajar dengan performa akademik yang dicapai.

Oleh karena itu, pada laporan ini dilakukan analisis terhadap dataset perilaku siswa untuk mengetahui bagaimana faktor-faktor seperti tingkat kehadiran, aktivitas belajar, dan penggunaan sumber pembelajaran dapat mempengaruhi performa akademik siswa.

1.2 Tujuan Analisis

1. Memahami karakteristik dataset perilaku siswa.
2. Mengidentifikasi hubungan antara tingkat kehadiran dan performa akademik.
3. Melakukan eksplorasi data untuk menemukan pola yang mempengaruhi prestasi siswa.
4. Menyajikan hasil analisis dalam bentuk visualisasi yang mudah dipahami.
5. Memberikan insight yang dapat membantu pengambilan keputusan dalam bidang pendidikan.

BAB II

PEMBAHASAN

2.1 Business Understanding

Tahapan Business Understanding merupakan langkah awal dalam proses analisis data yang bertujuan untuk memahami permasalahan yang ingin diselesaikan serta tujuan analisis yang ingin dicapai.

Dalam konteks pendidikan, keberhasilan akademik siswa merupakan salah satu indikator penting dalam menilai efektivitas proses pembelajaran. Namun, performa akademik tidak hanya dipengaruhi oleh kemampuan akademik semata, melainkan juga oleh berbagai faktor lain seperti kebiasaan belajar, tingkat kehadiran, serta keterlibatan siswa dalam aktivitas pembelajaran.

2.1.1 Business Objective

Tujuan utama dari proyek ini adalah untuk memahami hubungan antara tingkat kehadiran siswa dengan prestasi akademik mereka di lingkungan pendidikan vokasi. Pihak sekolah ingin memastikan apakah absensi merupakan faktor penentu utama keberhasilan siswa, sehingga mereka dapat membuat strategi untuk menekan angka ketidakhadiran dan meningkatkan kualitas lulusan.

2.1.2 Assess Situation

Saat ini, data perilaku digital siswa (seperti penggunaan internet, interaksi di forum, dan video belajar) sudah tersedia, namun belum dianalisis secara mendalam bersama data kehadiran fisik. Masalah yang sering muncul adalah siswa dengan tingkat kehadiran rendah cenderung memiliki risiko kegagalan ujian yang tinggi, namun belum ada alat ukur pasti untuk memprediksi sejauh mana dampak tersebut secara keseluruhan.

2.1.3 Analytic Goals

1. Pengolahan Data: Membersihkan dataset dari data kosong menggunakan teknik *KNNImputer* dan membuang data duplikat.
2. Eksplorasi Data (EDA): Membuat visualisasi (Bar, Pie, Scatter, dll) untuk melihat distribusi data.
3. Analisis Korelasi: Menilai hubungan antar variabel untuk mengambil kesimpulan.
4. Dokumentasi: Menyusun laporan hasil analisis dan menyimpan dataset yang sudah bersih untuk kebutuhan di masa mendatang.

2.1.4 Project Plan

1. Pengolahan Data: Membersihkan dataset dari data kosong menggunakan teknik *KNNImputer* dan membuang data duplikat.
2. Eksplorasi Data (EDA): Membuat visualisasi (Bar, Pie, Scatter, dll) untuk melihat distribusi data.
3. Analisis Korelasi: Menilai hubungan antar variabel untuk mengambil kesimpulan.
4. Dokumentasi: Menyusun laporan hasil analisis dan menyimpan dataset yang sudah bersih untuk kebutuhan di masa mendatang.

2.2 Data Understanding

Tahap Data Understanding bertujuan untuk memahami struktur dataset yang digunakan sebelum dilakukan analisis lebih lanjut. Pada tahap ini dilakukan proses eksplorasi data untuk mengetahui karakteristik data, jenis variabel, serta potensi permasalahan yang terdapat dalam dataset.

Dataset dimuat menggunakan library Pandas :

2.2.1 Memuat Dataset

Sebelum melakukan proses analisis data, terlebih dahulu dilakukan proses import beberapa library Python yang digunakan untuk membantu proses pengolahan data, analisis statistik, serta visualisasi data.

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import plotly.express as px
import numpy as np
from sklearn.impute import KNNImputer
```

1. Library **Pandas** digunakan untuk memuat serta mengelola dataset dalam bentuk struktur data **DataFrame**, yang memungkinkan data disimpan dalam bentuk tabel sehingga lebih mudah untuk dianalisis dan dimanipulasi.
2. Library **NumPy** digunakan untuk mendukung operasi numerik dan komputasi matematis dalam proses analisis data.
3. Library **Matplotlib** digunakan untuk membuat berbagai jenis visualisasi data seperti grafik distribusi, diagram batang, serta grafik lainnya yang membantu dalam memahami pola data.

4. Library **Seaborn** merupakan library visualisasi yang dibangun di atas Matplotlib dan digunakan untuk membuat visualisasi statistik yang lebih informatif seperti heatmap, boxplot, dan distribusi data.
5. Library **Plotly Express** digunakan untuk membuat visualisasi data yang bersifat interaktif sehingga memudahkan pengguna dalam mengeksplorasi hasil analisis data.
6. Library **Scikit-Learn**, khususnya modul **KNNImputer**, digunakan untuk menangani permasalahan missing value dengan menggunakan metode **K-Nearest Neighbor**, yaitu mengisi nilai yang hilang berdasarkan nilai dari data yang memiliki karakteristik paling dekat.

Setelah seluruh library yang diperlukan diimpor, langkah selanjutnya adalah memuat dataset yang akan dianalisis.

```
df = pd.read_csv('vocational_student_behavioral_dataset_V4.csv')
df.head()
```

Kode di atas digunakan untuk membaca dataset yang tersimpan dalam format CSV menggunakan fungsi `read_csv()` dari library Pandas. Dataset kemudian disimpan dalam variabel **df** dalam bentuk DataFrame.

Fungsi `head()` digunakan untuk menampilkan beberapa baris pertama dari dataset sehingga dapat memberikan gambaran awal mengenai struktur data, seperti nama kolom, jenis data yang terdapat pada setiap kolom, serta format informasi yang digunakan dalam dataset. Tahapan ini penting dilakukan untuk memastikan bahwa dataset telah berhasil dimuat dengan benar sebelum dilakukan proses analisis data lebih lanjut.

2.2.2 Melihat Struktur Data

```
df.info()
```

Fungsi `info()` digunakan untuk menampilkan informasi penting mengenai dataset, seperti:

1. jumlah baris data
2. jumlah kolom
3. tipe data setiap kolom
4. jumlah nilai yang tidak kosong

Informasi ini sangat penting untuk memahami apakah terdapat kolom yang memiliki missing value atau tipe data yang tidak sesuai.

2.2.3 Statistik Deskriptif

```
df.describe(include='all')
```

Statistik deskriptif digunakan untuk melihat ringkasan data numerik dalam dataset seperti:

1. nilai rata-rata (mean)
2. nilai minimum
3. nilai maksimum
4. standar deviasi
5. kuartil data

Melalui statistik deskriptif ini, peneliti dapat memahami distribusi data serta mengidentifikasi kemungkinan adanya nilai ekstrem atau outlier.

2.2.4 Verifikasi Kualitas Data

Tahap ini bertujuan untuk memastikan bahwa dataset berada dalam kondisi yang baik sebelum dilakukan analisis lebih lanjut.

```
df.dtypes
```

Digunakan untuk memastikan tipe data pada setiap kolom sudah sesuai, contoh:

1. numerik = integer / float
2. kategori = object / string

Jika tipe data tidak sesuai, maka perlu dilakukan konversi tipe data.

2.2.5 Inconsistensi Values

Inconsistent value adalah data yang memiliki penulisan yang tidak konsisten, contoh:

1. low
2. LOW
3. Low

```
df['performance_label'] = df['performance_label'].str.upper()
```

Standarisasi dilakukan agar data memiliki format yang konsisten.

2.2.6 Missing Values

Missing value adalah nilai yang kosong dalam dataset.

```
df.isna().sum()
```

Penanganan missing value dilakukan menggunakan metode **mean** pada data numerik.

```
df['quiz_score_avg'] = df['quiz_score_avg'].fillna(df['quiz_score_avg'].mean())
```

2.2.7 Duplicated Values

Digunakan untuk mengecek apakah terdapat data yang duplikat.

```
df.duplicated().sum()
```

Data duplikat dapat mempengaruhi hasil analisis sehingga perlu diperiksa sebelum proses analisis dilakukan.

2.2.8 Outliers Values

Outlier adalah nilai yang sangat berbeda dari sebagian besar data.

```
results = []
cols = df.select_dtypes(include=['float64', 'int64'])

for col in cols:
    q1 = df[col].quantile(0.25)
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
    lower_bound = q1 - 1.5*iqr
    upper_bound = q3 + 1.5*iqr
    outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
    percent_outliers = (len(outliers)/len(df))*100
    results.append({'Kolom': col, 'Persentase Outliers': percent_outliers})

# Dataframe dari list hasil
results_df = pd.DataFrame(results)
results_df.set_index('Kolom')
```

- Lower Bound = $Q1 - 1.5 \times IQR$
- Upper Bound = $Q3 + 1.5 \times IQR$

Nilai yang berada di luar batas tersebut dianggap sebagai outlier. Setelah itu dihitung persentase outlier terhadap jumlah total data. Hasil perhitungan kemudian disimpan dalam bentuk dataframe sehingga dapat dianalisis lebih lanjut.

2.3 Eksplorasi Data (EDA)

Exploratory Data Analysis (EDA) merupakan tahap analisis data yang bertujuan untuk memahami karakteristik dataset secara lebih mendalam melalui teknik statistik dan visualisasi

data. Pada tahap ini dilakukan berbagai eksplorasi terhadap dataset untuk menemukan pola, hubungan antar variabel, serta distribusi data yang dapat memberikan insight terhadap permasalahan yang dianalisis.


EDA dalam penelitian ini dilakukan menggunakan beberapa jenis visualisasi data seperti boxplot, bar chart, pie chart, histogram, dan heatmap. Visualisasi tersebut membantu dalam memahami pola perilaku siswa serta hubungan antara aktivitas belajar dengan performa akademik mereka.

2.3.1 Comparison

Analisis perbandingan dilakukan untuk melihat perbedaan tingkat aktivitas siswa dalam menggunakan sistem pembelajaran berdasarkan wilayah atau region. Dengan melakukan perbandingan ini, dapat diketahui wilayah mana yang memiliki tingkat keterlibatan siswa yang lebih tinggi terhadap platform pembelajaran.

```
login_region = df.groupby('region')['total_logins'].sum().sort_values(ascending=False)
plt.figure(figsize=(10,6))
sns.barplot(
    x=login_region.index,
    y=login_region.values,
    palette='viridis',
    hue=login_region.index,
    legend=False
)
plt.title('Total Login Berdasarkan Region')
plt.xlabel('Region')
plt.ylabel('Total Logins')
plt.xticks(rotation=45)
plt.show()
```

Kode di atas digunakan untuk membandingkan jumlah total login siswa pada setiap region. Data terlebih dahulu dikelompokkan berdasarkan kolom region menggunakan fungsi `groupby()`, kemudian jumlah login pada setiap wilayah dihitung menggunakan fungsi `sum()`. Hasilnya diurutkan dari nilai terbesar ke terkecil menggunakan `sort_values()` agar region dengan jumlah login tertinggi dapat terlihat dengan jelas.



Gambar 2. 1 Comparison

Berdasarkan grafik tersebut dapat terlihat bahwa terdapat perbedaan jumlah login siswa pada setiap region. Beberapa wilayah memiliki jumlah login yang lebih tinggi dibandingkan wilayah lainnya. Hal ini menunjukkan bahwa tingkat aktivitas penggunaan sistem pembelajaran oleh siswa dapat berbeda-beda pada setiap wilayah. Informasi ini dapat digunakan untuk memahami tingkat keterlibatan siswa terhadap platform pembelajaran yang digunakan.

2.3.2 Composition


Analisis komposisi dilakukan untuk melihat proporsi kategori performa mahasiswa dalam dataset. Dengan mengetahui komposisi ini, dapat dipahami bagaimana distribusi jumlah mahasiswa pada setiap kategori performa yang terdapat dalam data.

```
performance_dist = df['performance_label'].value_counts()

plt.figure(figsize=(8, 9))
performance_dist.plot(
    kind='pie',
    autopct='%1.1f%%',
    startangle=140
)
plt.title('Proporsi Performa Mahasiswa')
plt.ylabel("")
```

```
plt.axis('equal')  
plt.show()
```

Kode di atas digunakan untuk menghitung jumlah data pada setiap kategori `performance_label` menggunakan fungsi `value_counts()`. Hasil perhitungan tersebut kemudian divisualisasikan dalam bentuk pie chart untuk menunjukkan proporsi masing-masing kategori performa mahasiswa.



Gambar 2. 2 *Composition*


2.3.3 Distribution

Analisis distribusi dilakukan untuk melihat pola penyebaran nilai pada suatu variabel dalam dataset. Pada bagian ini, distribusi yang dianalisis adalah `overall_performance_score` untuk mengetahui bagaimana penyebaran skor performa mahasiswa secara keseluruhan.

```
plt.figure(figsize=(10, 6))  
sns.histplot(df['overall_performance_score'], bins=20, kde=True)  
plt.title('Distribusi Overall Performance Score')
```

```
plt.xlabel('Overall Performance Score')  
plt.ylabel('Frekuensi')  
plt.show()
```

Kode di atas digunakan untuk membuat histogram yang menampilkan distribusi nilai dari kolom `overall_performance_score`. Histogram dibuat menggunakan fungsi `sns.histplot()` dari library Seaborn. Parameter `bins=20` digunakan untuk membagi data ke dalam 20 kelompok interval sehingga distribusi data dapat terlihat lebih jelas. Sementara itu, parameter `kde=True` digunakan untuk menambahkan kurva Kernel Density Estimation (KDE) yang membantu memperlihatkan pola distribusi data secara lebih halus.



Gambar 2.3 *Distribution*


Berdasarkan grafik tersebut dapat terlihat bagaimana penyebaran nilai overall performance score pada dataset. Histogram menunjukkan frekuensi kemunculan skor pada setiap interval nilai, sehingga dapat memberikan gambaran apakah data cenderung terpusat pada nilai tertentu atau tersebar secara merata.

2.3.4 Relationship

Analisis relationship dilakukan untuk melihat hubungan atau keterkaitan antara dua variabel dalam dataset. Pada bagian ini dianalisis hubungan antara `attendance_percentage` (persentase kehadiran mahasiswa) dengan `overall_performance_score` (skor performa keseluruhan mahasiswa).

```
plt.figure(figsize=(8, 6))
sns.heatmap(
    df[['attendance_percentage', 'overall_performance_score']].corr(),
    annot=True,
    cmap='viridis',
    fmt='.2f'
)
plt.title('Korelasi Kehadiran dan Performa Mahasiswa')
plt.show()
```

Kode di atas digunakan untuk membuat heatmap korelasi antara dua variabel. Pertama, dipilih kolom `attendance_percentage` dan `overall_performance_score`, kemudian dihitung nilai korelasinya menggunakan fungsi `corr()`. Hasil korelasi tersebut kemudian divisualisasikan menggunakan fungsi `sns.heatmap()` dari library Seaborn.



Gambar 2. 4 Relationship

Berdasarkan visualisasi tersebut dapat terlihat nilai korelasi antara persentase kehadiran mahasiswa dan skor performa mahasiswa. Nilai korelasi ini menunjukkan seberapa kuat hubungan antara kedua variabel tersebut. Semakin mendekati nilai 1, maka hubungan antara kedua variabel semakin kuat dan searah, sedangkan nilai yang mendekati 0 menunjukkan hubungan yang lemah. Grafik ini membantu memahami apakah tingkat kehadiran mahasiswa berpengaruh terhadap performa akademiknya.

2.4 Data Preparation

Data preparation merupakan tahapan penting dalam proses analisis data yang bertujuan untuk menyiapkan data agar siap digunakan dalam proses analisis atau pemodelan lebih lanjut. Pada tahap ini dilakukan berbagai proses seperti pembersihan data, pemilihan variabel yang relevan, serta penyesuaian format data agar sesuai dengan kebutuhan analisis.

2.4.1 Inconsistent Values

Langkah ini dilakukan untuk memastikan bahwa data kategori dalam dataset memiliki format penulisan yang konsisten. Pada beberapa dataset, sering ditemukan perbedaan penulisan seperti huruf kecil, huruf besar, atau campuran keduanya. Jika tidak diseragamkan, komputer dapat menganggap data tersebut sebagai kategori yang berbeda meskipun sebenarnya sama.

```
# 1. Menyeragamkan kolom 'performance_label' (Status Performa)
df['performance_label'] = df['performance_label'].str.upper()

# 2. Menyeragamkan kolom 'region' (Wilayah)
df['region'] = df['region'].str.upper()

# 3. Menyeragamkan kolom 'socioeconomic_status' (Status Ekonomi)
df['socioeconomic_status'] = df['socioeconomic_status'].str.upper()

# Menampilkan hasil unik untuk memastikan data sudah rapi
print(df['performance_label'].unique())
print(df['region'].unique())
```

Kode di atas digunakan untuk menyeragamkan format teks pada beberapa kolom kategori dalam dataset. Fungsi `.str.upper()` digunakan untuk mengubah seluruh teks pada kolom menjadi

huruf kapital. Kolom yang dilakukan standarisasi antara lain performance_label, region, dan socioeconomic_status.

```
[‘HIGH’ ‘LOW’ ‘MEDIUM’]  
[‘WEST’ ‘SOUTH’ ‘NORTH’ ‘EAST’]
```

Berdasarkan hasil tersebut dapat disimpulkan bahwa seluruh data pada kolom kategori telah memiliki format yang konsisten dan tidak ditemukan perbedaan penulisan pada kategori yang sama. Dengan demikian, data sudah siap digunakan untuk proses analisis selanjutnya.

2.4.2 Missing Values

Pengecekan missing values dilakukan untuk mengetahui apakah terdapat nilai yang kosong dalam dataset. Keberadaan data yang hilang dapat mempengaruhi hasil analisis sehingga perlu dideteksi dan ditangani sebelum melanjutkan ke tahap analisis berikutnya.

```
print((df.isna().sum() / len(df)) * 100)
```

Kode di atas digunakan untuk menghitung persentase nilai kosong pada setiap kolom dalam dataset. Fungsi isna() digunakan untuk mendeteksi nilai yang hilang, kemudian dihitung jumlahnya dan dikonversi menjadi persentase terhadap total data.

A. Analisis Temuan

Berdasarkan hasil pengecekan, ditemukan missing values sebesar 3.0% pada beberapa kolom numerik, yaitu:

1. avg_session_duration
2. resource_click_count
3. daily_internet_usage_mins
4. quiz_score_avg

B. Penanganan Missing Values

Untuk menangani nilai yang hilang tanpa mengurangi jumlah data, dilakukan imputasi menggunakan nilai rata-rata (mean) pada setiap kolom yang memiliki missing values.

```
df['avg_session_duration']  
df['avg_session_duration'].fillna(df['avg_session_duration'].dropna().mean())  
df['resource_click_count']  
df['resource_click_count'].fillna(df['resource_click_count'].dropna().mean())
```

```
df['daily_internet_usage_mins'] =
df['daily_internet_usage_mins'].fillna(df['daily_internet_usage_mins'].dropna().mean())
df['quiz_score_avg'] = df['quiz_score_avg'].fillna(df['quiz_score_avg'].dropna().mean())
```

Kode di atas digunakan untuk mengganti nilai kosong dengan nilai rata-rata dari masing-masing kolom menggunakan fungsi fillna().

C. Verifikasi

Setelah proses imputasi, dilakukan pengecekan kembali untuk memastikan tidak ada nilai kosong yang tersisa.

```
pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio %'])
```

Kesimpulannya adalah seluruh missing values berhasil ditangani dengan metode imputasi rata-rata, sehingga dataset sudah lengkap dan dapat digunakan pada tahap analisis selanjutnya.

2.4.3 Duplicated Values

Tahap ini dilakukan untuk memastikan bahwa tidak terdapat data yang duplikat (ganda) dalam dataset. Data yang duplikat dapat mempengaruhi hasil analisis karena satu data yang sama dapat terhitung lebih dari satu kali.

```
df[df.duplicated()]
df = df.drop_duplicates()
```

Kode df.duplicated() digunakan untuk mendeteksi apakah terdapat baris data yang memiliki nilai yang sama pada seluruh kolom. Jika ditemukan data yang duplikat, maka baris tersebut dapat dihapus menggunakan fungsi drop_duplicates().

Kesimpulannya adalah berdasarkan hasil pengecekan, tidak ditemukan data duplikat dalam dataset. Hal ini menunjukkan bahwa setiap baris data sudah merepresentasikan satu data yang unik sehingga dataset dapat digunakan dengan aman untuk proses analisis selanjutnya.

2.4.4 Outliers Values

Outlier merupakan nilai data yang berada jauh di luar jangkauan mayoritas data lainnya. Nilai yang terlalu tinggi atau terlalu rendah dapat mempengaruhi hasil analisis, terutama pada perhitungan statistik seperti rata-rata dan distribusi data. Oleh karena itu, perlu dilakukan pengecekan untuk mengetahui apakah terdapat outlier pada dataset.

```
results = []
cols = df.select_dtypes(include=['float64', 'int64']).drop(columns=['student_id'],
errors='ignore')
```

```

for col in cols:
    q1 = df[col].quantile(0.25)
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
    lower_bound = q1 - 1.5 * iqr
    upper_bound = q3 + 1.5 * iqr
    outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
    percent_outliers = (len(outliers) / len(df)) * 100
    results.append({'Kolom': col, 'Persentase Outliers': percent_outliers})

results_df = pd.DataFrame(results)
results_df.set_index('Kolom', inplace=True)
display(results_df)

```

Kode di atas digunakan untuk mendeteksi outlier pada setiap kolom numerik dalam dataset menggunakan metode Interquartile Range (IQR). Nilai Q1 dan Q3 digunakan untuk menghitung rentang IQR, kemudian ditentukan batas bawah dan batas atas data. Nilai yang berada di luar batas tersebut dianggap sebagai outlier. Hasilnya ditampilkan dalam bentuk tabel yang menunjukkan persentase outlier pada setiap kolom.

Berdasarkan hasil pengecekan, sebagian besar kolom memiliki persentase outlier yang sangat kecil (di bawah 1%). Meskipun jumlahnya tidak signifikan, nilai ekstrem tersebut tetap perlu ditangani agar tidak mempengaruhi hasil analisis.

A. Penanganan Outliers

Untuk menangani outlier tanpa menghapus data, digunakan teknik clipping, yaitu membatasi nilai yang terlalu ekstrem agar tetap berada dalam rentang batas yang wajar.

```

columns_to_impute = ["avg_session_duration", "daily_internet_usage_mins",
"quiz_score_avg"]

for col in columns_to_impute:
    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = Q1 - 1.5 * IQR

```

```
upper_bound = Q3 + 1.5 * IQR
```

```
df.loc[:, col] = df[col].clip(lower=lower_bound, upper=upper_bound)
```

Kode di atas membatasi nilai yang berada di luar batas bawah dan batas atas menggunakan fungsi clip(). Dengan cara ini, nilai yang terlalu ekstrem akan disesuaikan ke batas yang masih dianggap wajar tanpa harus menghapus baris data dari dataset.

Kesimpulan nya adalah Secara umum dataset memiliki kualitas yang baik karena hampir semua kolom memiliki persentase outlier yang sangat kecil. Dengan menggunakan teknik clipping, nilai-nilai ekstrem berhasil dirapikan sehingga dataset menjadi lebih stabil dan siap digunakan untuk analisis selanjutnya.

2.4.5 Data Reduction

Reduksi data bertujuan untuk menyederhanakan dataset dengan menghapus variabel yang tidak relevan atau tidak memberikan kontribusi langsung dalam analisis. Dengan dataset yang lebih ringkas, proses analisis dapat menjadi lebih fokus dan efisien.

```
df = df.drop('student_id', axis=1)
```

```
df = df[df['region'] != 'UNKNOWN']
```

```
display(df.head())
```

Kode `df.drop('student_id', axis=1)` digunakan untuk menghapus kolom `student_id` dari dataset. Kolom ini merupakan identitas unik setiap siswa sehingga tidak memiliki nilai analitis dalam proses pengolahan data.

Selanjutnya, kode `df[df['region'] != 'UNKNOWN']` digunakan untuk melakukan filtering data, yaitu menghapus baris yang memiliki nilai wilayah 'UNKNOWN'. Langkah ini dilakukan agar dataset hanya berisi data yang valid dan dapat digunakan dalam analisis.

Perintah `display(df.head())` digunakan untuk menampilkan beberapa baris pertama dari dataset sebagai bentuk verifikasi bahwa proses reduksi data telah berhasil dilakukan.

Kesimpulan nya adalah melalui proses reduksi data ini, kolom yang tidak diperlukan seperti `student_id` berhasil dihapus dan data dengan kategori wilayah yang tidak valid telah disaring. Dengan demikian dataset menjadi lebih bersih, ringkas, dan siap digunakan untuk proses analisis selanjutnya.

2.5 Visualisasi Data (Tableau)


Ada tahap ini dilakukan visualisasi data menggunakan Tableau untuk menampilkan data dalam bentuk grafik agar lebih mudah dipahami. Visualisasi ini membantu melihat pola, perbandingan, serta hubungan antar variabel dalam dataset.

Grafik yang dibuat kemudian disusun dalam sebuah dashboard sehingga informasi dari data dapat dilihat dengan lebih jelas dan interaktif.

2.5.1 Pie Chart

Visualisasi pie chart digunakan untuk menampilkan komposisi atau perbandingan jumlah mahasiswa berdasarkan kategori performa akademik, yaitu High, Medium, dan Low. Setiap potongan pada pie chart menunjukkan persentase jumlah mahasiswa dalam masing-masing kategori.

Dari grafik ini dapat terlihat bagaimana distribusi performa mahasiswa secara keseluruhan. Jika kategori Medium memiliki porsi terbesar, maka dapat disimpulkan bahwa sebagian besar mahasiswa berada pada tingkat performa sedang. Sementara itu, kategori High dan Low menunjukkan jumlah mahasiswa dengan performa tinggi dan rendah.




Gambar 2. 5 Pie Chart

2.5.2 Bar Chart

Bar chart digunakan untuk membandingkan total aktivitas login mahasiswa pada platform pembelajaran berdasarkan wilayah (region). Setiap batang pada grafik mewakili satu wilayah dan tinggi batang menunjukkan jumlah total login mahasiswa dari wilayah tersebut.

Melalui visualisasi ini dapat dilihat wilayah mana yang memiliki aktivitas login paling tinggi dan wilayah mana yang memiliki aktivitas lebih rendah. Aktivitas login yang tinggi dapat menunjukkan bahwa mahasiswa dari wilayah tersebut lebih aktif mengakses platform pembelajaran.




Gambar 2. 6 Bar Chart

2.5.3 Scatter Plot

Scatter plot digunakan untuk melihat hubungan antara persentase kehadiran mahasiswa dengan skor performa akademik. Setiap titik pada grafik merepresentasikan satu data mahasiswa.

Sumbu horizontal menunjukkan attendance percentage, sedangkan sumbu vertikal menunjukkan overall performance score. Dengan melihat pola penyebaran titik pada grafik, dapat diamati apakah terdapat kecenderungan hubungan antara kehadiran dan performa akademik.

Jika titik-titik cenderung membentuk pola meningkat, maka dapat disimpulkan bahwa mahasiswa dengan tingkat kehadiran yang lebih tinggi cenderung memiliki performa akademik yang lebih baik.




Gambar 2. 7 Scatter Plot

2.5.4 Histogram

Histogram digunakan untuk melihat penyebaran nilai overall performance score mahasiswa dalam dataset. Grafik ini menampilkan seberapa sering nilai tertentu muncul dengan membagi data ke dalam beberapa kelompok nilai (bins).


Dari histogram ini dapat diketahui apakah nilai performa mahasiswa cenderung terkonsentrasi pada rentang tertentu, misalnya pada nilai menengah, atau tersebar secara merata. Jika sebagian besar nilai berada di tengah, maka dapat disimpulkan bahwa mayoritas mahasiswa memiliki tingkat performa yang sedang.

Visualisasi ini membantu memahami pola distribusi performa akademik mahasiswa secara keseluruhan.



Gambar 2. 8 Histogram

2.6 Dashboard



Gambar 2. 9 Dashboard

Dashboard dibuat untuk menggabungkan seluruh visualisasi data dalam satu tampilan yang terintegrasi sehingga memudahkan pengguna dalam memahami informasi dari dataset secara keseluruhan.

Pada dashboard ini terdapat beberapa grafik utama, yaitu pie chart yang menunjukkan proporsi performa mahasiswa, bar chart yang menampilkan perbandingan aktivitas login berdasarkan wilayah, histogram yang memperlihatkan distribusi nilai performa mahasiswa, serta scatter plot yang menggambarkan hubungan antara tingkat kehadiran dan performa akademik.

Dengan menggabungkan seluruh visualisasi tersebut dalam satu dashboard, pengguna dapat melihat berbagai aspek data secara bersamaan. Hal ini membantu dalam memahami pola perilaku belajar mahasiswa, aktivitas penggunaan platform pembelajaran, serta faktor-faktor yang berkaitan dengan performa akademik mahasiswa.

Dashboard ini juga memudahkan proses analisis karena informasi yang sebelumnya tersebar dalam berbagai grafik kini dapat diamati dalam satu tampilan yang lebih jelas dan informatif.

2.7 Hasil Analisis

Berdasarkan proses analisis data yang telah dilakukan mulai dari tahap data understanding, verifikasi kualitas data, eksplorasi data (EDA), hingga visualisasi data, diperoleh beberapa temuan penting mengenai perilaku dan performa mahasiswa dalam dataset.

Dari visualisasi pie chart, diketahui bahwa sebagian besar mahasiswa berada pada kategori performa sedang (Medium). Hal ini menunjukkan bahwa mayoritas mahasiswa memiliki tingkat performa akademik yang cukup stabil, meskipun masih terdapat sebagian mahasiswa dengan performa tinggi (High) dan performa rendah (Low).

Selanjutnya, pada visualisasi bar chart yang membandingkan total login berdasarkan wilayah (region), terlihat adanya perbedaan tingkat aktivitas mahasiswa dalam mengakses platform pembelajaran. Beberapa wilayah menunjukkan jumlah login yang lebih tinggi dibandingkan wilayah lainnya. Hal ini mengindikasikan bahwa aktivitas belajar secara digital dapat dipengaruhi oleh faktor wilayah atau lingkungan belajar mahasiswa.

Visualisasi histogram yang menampilkan distribusi nilai overall performance score menunjukkan bahwa sebagian besar nilai mahasiswa terkonsentrasi pada rentang nilai menengah. Hal ini sejalan dengan hasil pie chart yang menunjukkan bahwa mayoritas mahasiswa berada pada kategori performa sedang.

Selain itu, pada scatter plot yang menggambarkan hubungan antara attendance percentage dan overall performance score, terlihat adanya kecenderungan hubungan positif antara tingkat kehadiran dan performa akademik mahasiswa. Mahasiswa yang memiliki tingkat kehadiran

lebih tinggi cenderung memiliki nilai performa yang lebih baik. Hal ini menunjukkan bahwa kehadiran dalam kegiatan pembelajaran memiliki peran penting dalam meningkatkan hasil belajar mahasiswa.

Secara keseluruhan, hasil analisis ini menunjukkan bahwa faktor-faktor seperti kehadiran, aktivitas pada platform pembelajaran, serta kondisi distribusi nilai mahasiswa memiliki keterkaitan dengan performa akademik mahasiswa.

BAB III

PENUTUP

3.1 Kesimpulan

Berdasarkan seluruh proses pengolahan dan analisis data yang telah dilakukan, dapat disimpulkan bahwa dataset yang digunakan memiliki kualitas yang baik setelah melalui tahap pembersihan dan verifikasi data. Proses seperti pengecekan tipe data, penanganan missing values, pengecekan duplikasi, serta penanganan outlier berhasil membuat dataset menjadi lebih bersih dan siap digunakan untuk analisis lebih lanjut.

Hasil eksplorasi data menunjukkan bahwa sebagian besar mahasiswa memiliki tingkat performa akademik yang berada pada kategori sedang. Hal ini menunjukkan bahwa performa mahasiswa dalam dataset ini relatif stabil, meskipun masih terdapat sebagian mahasiswa yang memiliki performa tinggi maupun rendah.

Selain itu, aktivitas mahasiswa dalam menggunakan platform pembelajaran juga menunjukkan adanya perbedaan berdasarkan wilayah. Beberapa wilayah memiliki tingkat aktivitas login yang lebih tinggi dibandingkan wilayah lainnya. Hal ini dapat mengindikasikan adanya perbedaan dalam kebiasaan belajar digital atau akses terhadap sumber pembelajaran.

Hubungan antara tingkat kehadiran mahasiswa dengan performa akademik juga menunjukkan kecenderungan yang positif. Mahasiswa dengan tingkat kehadiran yang lebih tinggi cenderung memiliki skor performa yang lebih baik. Hal ini menunjukkan bahwa kehadiran dalam kegiatan pembelajaran memiliki peran penting dalam mendukung keberhasilan akademik mahasiswa.

Dengan menggunakan visualisasi data melalui dashboard pada Tableau, informasi yang terdapat dalam dataset dapat ditampilkan secara lebih jelas dan mudah dipahami. Dashboard yang dibuat mampu menyajikan berbagai aspek data secara terintegrasi sehingga membantu dalam proses analisis dan interpretasi data.

Secara keseluruhan, proses analisis ini memberikan gambaran yang cukup jelas mengenai pola perilaku belajar mahasiswa serta faktor-faktor yang berkaitan dengan performa akademik mereka.

3.2 Saran

Berdasarkan hasil analisis yang telah dilakukan, terdapat beberapa saran yang dapat dipertimbangkan untuk pengembangan analisis maupun penelitian selanjutnya.

1. Penelitian selanjutnya dapat mempertimbangkan untuk menambahkan variabel lain yang berkaitan dengan aktivitas belajar mahasiswa, seperti durasi waktu belajar, tingkat partisipasi dalam forum diskusi, atau penggunaan sumber belajar tambahan. Dengan adanya variabel tambahan tersebut, analisis yang dilakukan dapat memberikan gambaran yang lebih lengkap mengenai faktor-faktor yang memengaruhi performa akademik mahasiswa.
2. Analisis data dapat dikembangkan dengan menggunakan metode analisis yang lebih lanjut, seperti teknik machine learning atau pemodelan prediktif. Metode tersebut dapat digunakan untuk memprediksi performa akademik mahasiswa berdasarkan pola perilaku belajar yang terdapat dalam dataset.
3. Visualisasi data yang telah dibuat dapat terus dikembangkan dengan menambahkan fitur interaktif pada dashboard, seperti filter wilayah, kategori performa, atau rentang nilai tertentu. Hal ini akan memudahkan pengguna dalam melakukan eksplorasi data secara lebih mendalam sesuai dengan kebutuhan analisis.
4. Hasil analisis ini dapat dijadikan sebagai dasar untuk memahami perilaku belajar mahasiswa dalam lingkungan pembelajaran digital. Informasi yang diperoleh dapat membantu pihak pengelola pendidikan dalam merancang strategi pembelajaran yang lebih efektif untuk meningkatkan performa akademik mahasiswa.